INSTITUTO POLITÉCNICO NACIONAL

ESCUELA SUPERIOR DE CÓMPUTO

UNIDAD DE APRENDIZAJE

Procesamiento Digital de Señales

Informe de Primer Avance

Sistema Inteligente de Detección de Notas Musicales

Profesor

Jaime Hugo Puebla Lomas

Integrantes

Garcia Osornio Angel Heron

Peréz Tamayo Guadalupe Griselda

Ramírez Nolasco Alan Gabriel

Saavedra Duran Luis Daniel

Grupo

5CM1

Fecha

Octubre 5 de 2026

1. Introducción y Objetivo General

El proyecto se centra en el desarrollo de un sistema basado en inteligencia artificial orientado al procesamiento y análisis de señales acústicas. El objetivo fundamental es ingerir archivos digitales de audio (en formato WAV), realizar un análisis profundo para extraer sus características frecuenciales y, a partir de esto, aplicar modelos predictivos que identifiquen las notas musicales presentes.

2. Metodología de Trabajo

Investigación y diseño teórico

Inmersión en las bases matemáticas del procesamiento de señales sonoras y la conceptualización de la arquitectura de software.

Gestión y acondicionamiento de datos

Recopilación, limpieza y segmentación del conjunto de datos (dataset) auditivo requerido para el entrenamiento de los algoritmos.

Módulo del procesamiento de señales

Desarrollo de rutinas computacionales basadas en modelos matemáticos (tales como la Transformada de Fourier) enfocadas en la extracción de frecuencias fundamentales y la generación de perfiles acústicos (cromagramas).

Módulo de aprendizaje automático

Diseño, entrenamiento y evaluación métrica de modelos predictivos de inteligencia artificial (ej. Máquinas de Soporte Vectorial o arquitecturas similares) orientados a la clasificación unívoca de las notas.

2.2 Estado del Arte

La transcripción automática de música (*Automatic Music Transcription*, AMT) ha transitado desde modelos heurísticos basados en umbrales estáticos hasta arquitecturas híbridas que combinan el Procesamiento Digital de Señales (DSP) de alta resolución con técnicas de aprendizaje estadístico. En el caso específico de instrumentos de cuerda pulsada como la guitarra, el desafío principal radica en la presencia de transitorios no estacionarios, armónicos complejos y solapamiento espectral. El estado del arte actual se fundamenta en los siguientes pilares matemático-computacionales:

A. Representación Tiempo - Frecuencia

Dado que una señal de audio acústica $x[n]$ es estrictamente no estacionaria, el análisis mediante la Transformada de Fourier Global resulta insuficiente porque pierde la resolución temporal. El estado del arte resuelve esto mediante la **STFT**, la cual segmenta la señal en ventanas temporales superpuestas mediante una función de ventana $w[n]$ (típicamente Hamming o Hann) para minimizar la fuga espectral (*spectral leakage*).

Matemáticamente, la STFT se define en su forma discreta como:

$$X(m, \omega) = \sum_{n=-\infty}^{\infty} x[n] w[n - mR] e^{-j\omega n}$$

Donde:

- $x[n]$ es la señal de audio digitalizada.
- $w[n]$ es la ventana de análisis de longitud finita.
- m representa el índice del fotograma temporal (*frame*).
- R es el factor de salto (*hop size* o tasa de solapamiento, comúnmente 50% o 75%).
- ω es la frecuencia angular discreta.

A partir de $X(m, \omega)$, se calcula la matriz de magnitud espectral $|X(m, \omega)|$, la cual sirve como base para la extracción de descriptores acústicos avanzados como los cromagramas y los coeficientes cepstrales de frecuencia Mel (MFCCs).

B. Detección de Transitorios (*Onset Detection*) por Envolvente de Energía Local

La identificación exacta del instante en que se ejecuta una nota musical (*onset*) es crítica para aislar eventos sonoros individuales. El estado del arte implementa funciones de novedad (*novelty functions*) basadas en la derivada temporal de la energía local de la señal.

1. Cálculo de la energía local con ventana deslizante:

$$E[n] = \sum_{m} x[m]^2 w[n - m]$$

2. Función de novedad mediante rectificación de media onda:
   Para aislar los incrementos bruscos de energía (ataques de púa en la guitarra) y descartar los decaimientos naturales (*decays*), se calcula la primera diferencia temporal de la energía rectificada:

$$ODF[n] = \frac{dE[n]}{dn} \approx E[n] - E[n - 1]$$

   Aplicando un operador de rectificación de media onda

$$HWR(z) = (z + |z|) / 2$$

$$Novelty[n] = HWR(ODF[n])$$

3. Algoritmo de Búsqueda de Picos:
   Los picos locales en la función de novedad que superen un umbral adaptativo λ son seleccionados como los instantes exactos de inicio de nota:
   $onsets = \{n \mid Novelty[n] > \lambda \; y \; Novelty[n] = max(Vecindario[n])\}$

C. Estimación de la Frecuencia Fundamental (f_0) mediante Autocorrelación

Para determinar la altura de la nota musical ejecutada, el sistema debe calcular la frecuencia fundamental (f_0) de cada segmento aislado. El método matemático de referencia se basa en la función de autocorrelación discreta $R_{xx}[k]$, que mide la similitud entre la señal y una versión desplazada de sí misma en k muestras:

$$R_{xx}[k] = \sum_{n=0}^{N-1-k} x[n]x[n+k]$$

El desfase o retardo óptimo (k_{opt}) que corresponde al período fundamental T_0 de la nota se localiza encontrando el primer pico máximo de $R_{xx}[k]$ (omitiendo el retardo en $k = 0$):

$$k_{opt} = \arg \max_{k \in [min_lag, max_lag]} R_{xx}[k]$$

A partir del retardo óptimo y la frecuencia de muestreo f_s, la frecuencia fundamental se determina mediante:

$$f_0 = \frac{f_s}{k_{opt}}$$

(Nota: En implementaciones de vanguardia avanzadas, este principio matemático se extiende a algoritmos probabilísticos como PYIN, que integran modelos ocultos de Márkov para evitar errores de salto de octava).

D. Modelado Estadístico y Clasificación No Lineal

Una vez extraídos los vectores de características acústicas $x_i \in R^d$ (compuestos por f_0, energía, centroides espectrales y contraste), el sistema realiza la clasificación de la nota musical mediante Máquinas de Soporte Vectorial (SVM) con núcleos no lineales.

El modelo busca un hiperplano óptimo en un espacio de alta dimensión que separe las clases de notas musicales maximizando el margen de separación. Dado que las características acústicas no son linealmente separables en el espacio original, se emplea una función kernel $\Phi(x)$ (como el Kernel Radial RBF):

$$K(x_i, x_j) = exp(-\gamma || x_i - x_j ||^2)$$

La función de optimización primal que resuelve el clasificador SVM está dada por:

$$\min_{w,\, b,\, \xi} ((1/2)||w||^2 + C\sum_{i=1}^{N} \xi_i)$$

Sujeta a las restricciones de margen flexible:

$$y_i(w \cdot \Phi(x_i) + b) \geq 1 - \xi_i, \xi_i \geq 0 \forall i$$

Donde:

- w y b definen la orientación y posición del hiperplano de decisión.
- C es el hiperparámetro de regularización que penaliza los errores de clasificación.
- ξ_i son variables de holgura (*slack variables*) que permiten manejar solapamientos de ruido en señales reales de guitarra.
- $y_i \in \{-1, +1\}$ representa la etiqueta de clase de la nota musical.

3. Análisis y Requerimientos del Sistema

Requerimientos Funcionales

RF01 - Módulo de Ingesta

El sistema debe contar con un selector de archivos que restrinja y valide de forma estricta la carga de audios únicamente en formato .WAV.

RF02 - Reproducción y validación

El dashboard debe permitir al usuario reproducir el audio cargado para confirmar su integridad antes del análisis.

RF03 - Preprocesamiento Visual

La interfaz debe mostrar una representación gráfica de la señal original y su correspondiente transformación en el dominio de la frecuencia (cromagramas o espectrogramas).

RF04 - Ejecución de Clasificación

Un control dedicado para disparar la inferencia del modelo de Inteligencia Artificial (ej. SVM), procesando las características extraídas.

RF05 - Visualización de Predicciones

Mostrar una línea de tiempo o partitura digital que represente visualmente la secuencia unívoca de notas musicales identificadas.

RF06 - Generación de Reportes

Un módulo de exportación que traduzca las predicciones de la IA y empaque la transcripción en un archivo PDF descargable.

Requerimientos No Funcionales

RNF01 - Alta Cohesión y Mantenibilidad

El código del dashboard (front-end) debe estar desacoplado de la lógica matemática de Fourier y los modelos predictivos, utilizando un patrón modular.

RNF02 - Tolerancia a Fallos

La interfaz debe capturar excepciones (archivos corruptos, saturación de ruido) y mostrar alertas en pantalla sin que el sistema colapse.

RNF03 - Tiempos Eficientes

Durante el procesamiento, el dashboard debe mostrar indicadores de carga (spinners/progress bars) para no penalizar la experiencia de usuario si el análisis tarda.

RNF04 - Precisión Predictiva

El dashboard debe exponer las métricas de evaluación del modelo (nivel de confianza general) junto a los resultados.

4. Arquitectura del Sistema

El ecosistema del software se divide conceptualmente en cuatro fases interconectadas:

1. **Ingesta de Datos**

Etapa responsable de recibir, leer y validar la integridad del archivo WAV ingresado al sistema.

2. **Preprocesamiento y Extracción de Atributos**

El núcleo de transformación, donde la señal original se limpia de ruidos, se fragmenta temporalmente y se analiza matemáticamente para extraer sus vectores numéricos distintivos.

3. **Clasificación mediante Inteligencia Artificial**

Fase predictiva que recibe los atributos numéricos y determina, mediante modelos previamente entrenados, qué notas musicales específicas fueron tocadas.

4. **Generador de Reportes**

Traductor final que mapea las decisiones de la IA en formato de texto y genera dinámicamente el documento PDF con la partitura o secuencia de notas.

Implementación del Backend y Procesamiento Digital (DSP):

El núcleo computacional del sistema se ha programado en Python utilizando bibliotecas especializadas en cálculo matricial y análisis espectral (numpy y scipy). El flujo se divide en tres capas funcionales:

Módulo de Ingesta (scipy.io.wavfile). Carga los archivos en formato .wav, realiza una conversión automática de canales estéreo a monofónicos mediante el promedio de amplitudes ($mean$), y normaliza la señal en el rango $[-1, 1]$ para evitar saturaciones numéricas.

Módulo de Preprocesamiento y DSP (scipy.signal). Implementa la Transformada de Fourier de Tiempo Corto (signal.stft) aplicando una ventana de Hamming ($N = 2048$, solapamiento de 50%) para generar la matriz espectral. Asimismo, calcula la envolvente de energía local mediante convolución y detecta los puntos de transición o *onsets* (signal.find_peaks) para aislar las notas individuales.

Módulo de Inferencia (IA preliminar). Ejecuta un análisis de autocorrelación temporal sobre los segmentos aislados para estimar la frecuencia fundamental (f_0), preparando los vectores de características que alimentarán al clasificador definitivo.

5. Interfaz del sistema

Para garantizar una experiencia de usuario fluida, robusta y con alta tolerancia a fallos (cumpliendo con los requerimientos RNF01, RNF02 y RNF03), se desarrolló una interfaz gráfica de escritorio de alta estabilidad. Su diseño adopta una temática de estudio de audio profesional (interfaz oscura basada en tonos mate `#121212`, con acentos en naranja cálido `#F57C00` y verde de validación `#66BB6A`).

Componentes del Dashboard

Panel de Ingesta

Permite ingresar la ruta del archivo de audio o activar un modo de simulación en memoria que genera un tono puro de prueba ($440Hz$), satisfaciendo los requerimientos funcionales RF01 y RF02.

Controladores Síncronos (DSP e IA)

Botones de ejecución modular que permanecen bloqueados por defecto para prevenir errores de ejecución, habilitándose de forma secuencial conforme el módulo anterior completa su tarea con éxito.

Monitor de Sistema

Un panel de texto en tiempo real que emite retroalimentación detallada de cada paso del procesamiento, estados de carga y resultados de la predicción, cumpliendo con el monitoreo visual exigido en el RF04 y RF05.

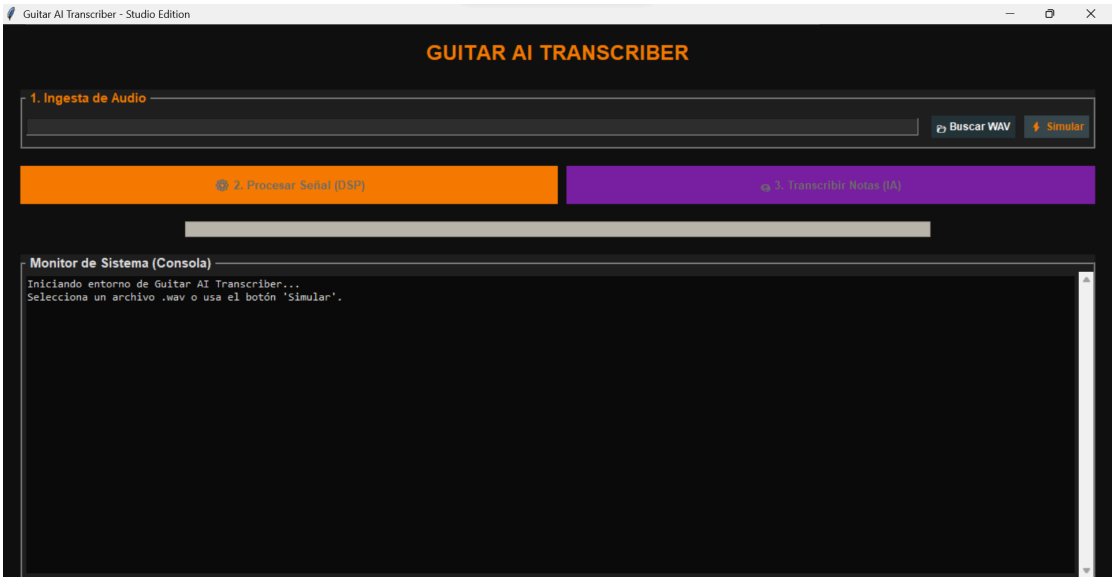


Figura 1. Vista general del dashboard central de la aplicación. Se observa la distribución por módulos funcionales: la barra de ingesta de señales de audio (WAV/Simulación), los controles de ejecución para el procesamiento digital de señales (DSP) y la predicción por inteligencia artificial, acompañados de una consola integrada de eventos del sistema.

6. Gestión de Riesgos y Mitigación

Dentro de la planeación se han considerado escenarios de riesgo técnico, destacando la posible dificultad algorítmica para diferenciar frecuencias excesivamente bajas, saturación de ruido en audios de baja calidad, o ineficiencias de comunicación interna entre módulos. Para garantizar la viabilidad del sistema, se han pautado rigurosas fases de calibración de hiperparámetros, un estricto pre-filtrado de las señales y arquitecturas de código tolerantes a fallos (manejo de excepciones).